

Relatório de Treino e Predição(BioPoints)

Data: 24/05/2026

Equipe: Samuel Cesar e Marcelo Silva

Sumário

Relatório de Treino e Predição(BioPoints)	1
1. Resumo Executivo.....	2
2. Compreensão do Problema e Hipóteses.....	3
2.1. Contexto de Negócio.....	3
2.2. Hipóteses Iniciais.....	3
3. Engenharia de Dados e Funcionalidades.....	4
3.1. Fontes de Dados.....	4
CO2 Emission by Vehicles (Open Data/Historical Base): Um dataset tabular contendo dados históricos de referência para milhares modelos de veículos. Ele mapeia as categorias(Marca, Modelo, Classe do Veículo, Transmissão, Tipo de Combustível) e especificações técnicas(Cilindrada, Cilindros, Consumo de Combustível Cidade/Estrada/Combinado). Isso serve tanto para dataset como Machine Learning model, assim como para consultas de referência(VehicleSpec table).....	4
3.2. Processamento e Engenharia de Funcionalidades.....	4
4. Modelação e Validação Científica.....	5
4.1. Arquitetura e Algoritmos.....	5
4.2. Estratégia de Validação.....	6
4.3. Desempenho e Métricas.....	7
5. Interpretabilidade do Modelo (XAI).....	9

1. Resumo Executivo

- **O Problema:** O modelo de previsão de CO₂ precisa estimar as emissões que um determinado veículo produziria por quilômetro usando combustíveis fósseis.
- **A Solução Científica:** Criar um modelo de regressão treinado com dados do dataset co2.csv, com o objetivo de retornar o valor de emissão de CO₂ a partir dos dados do veículo informados pelo usuário.
- **Impacto Projetado:**
 - Fornecer um modelo preditivo de emissões que estima a economia de CO₂ por evento de abastecimento.

2. Compreensão do Problema e Hipóteses

2.1. Contexto de Negócio

O projeto opera na interseção de Cidades Inteligentes, Mudanças Climáticas e Transição Energética, utilizando Salvador, Bahia, como ambiente piloto. O principal objetivo comercial é acelerar a transição de combustíveis fósseis para biocombustíveis (especificamente biodiesel) por meio de uma estrutura de incentivos mensurável e financeiramente recompensadora.

2.2. Hipóteses Iniciais

- **Hipótese 1:** As emissões de CO₂ de um veículo provenientes de combustíveis fósseis podem ser previstas com precisão utilizando parâmetros técnicos específicos (Engine Size, Cylinders, Transmission, Fuel Type, and Combined Fuel Consumption).
 - **Status: Confirmado.** O sistema utiliza um modelo de regressão treinado no dataset 'co2.csv' para mapear esses recursos de entrada diretamente para a variável alvo (CO2_Emissions_g_per_km), estabelecendo uma base confiável para o cálculo da economia.
- **Hipótese 2:** Um sistema de recompensas baseado apenas no volume total de combustível é insuficiente; ele deve incorporar a eficiência inerente do veículo para incentivar o comportamento sustentável.
 - **Status: Confirmado.** A lógica de negócios valida isso integrando um `efficiency_multiplier` (derivado das métricas de L(litro)/100 km) juntamente com a economia de CO₂, garantindo que os motoristas de veículos mais eficientes recebam bônus proporcionais.

3. Engenharia de Dados e Funcionalidades

3.1. Fontes de Dados

[CO2 Emission by Vehicles](#) (Open Data/Historical Base): Um dataset tabular contendo dados históricos de referência para milhares modelos de veículos. Ele mapeia as categorias(Marca, Modelo, Classe do Veículo, Transmissão, Tipo de Combustível) e especificações técnicas(Cilindrada, Cilindros, Consumo de Combustível Cidade/Estrada/Combinado). Isso serve tanto para dataset como Machine Learning model, assim como para consultas de referência(VehicleSpec table).

3.2. Processamento e Engenharia de Funcionalidades


- **Processamento:** Os cabeçalhos das colunas foram mapeados para convenções de nomenclatura robustas em termos de programação (por exemplo, Vehicle Class para Vehicle_type, CO2 Emissions(g/km) para CO2_Emissions_g_per_km) para evitar erros de análise na API e no pipeline
- **Codificação Categórica:** Devido à alta cardinalidade e à natureza de string de colunas específicas, um ColumnTransformer com OneHotEncoder(handle_unknown='ignore') foi implementado diretamente no pipeline do scikit-learn para Transmission, Fuel_Type, and Vehicle_type. Isso evitou erros durante a inferência no caso de algum um veículo recém-registrado possuir uma versão ou classe nunca vista antes.

4. Modelação e Validação Científica

4.1. Arquitetura e Algoritmos

Algoritmo: RandomForestRegressor (n_estimators=100, random_state=42)¹.

Justificativa: Inicialmente, foi realizada uma revisão da literatura, com base no livro *Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, especialmente nas seções sobre Bagging (p. 190) e Boosting (p. 196) e Random Forests (p. 193). Como estava lidando com um dataset composto em sua maioria, de características numéricas de carros, seria interessante utilizar um método que gerasse várias predições, encontrando uma média dos valores, em vez de abordagens sequenciais, como boosting, nas quais cada árvore busca corrigir os erros das anteriores. Dito isso, o Random Forest foi escolhido devido à sua alta resiliência ao lidar com dados tabulares “misturados” entre dados numéricos e texto codificado em one-hot. Ele captura relações não lineares (por exemplo, a interação entre 8 cilindros e como uma transmissão específica impacta as emissões exponencialmente em vez de linearmente) e é robusto a outliers² em comparação com modelos de regressão linear padrão.



1: n_estimators: Número de árvores; random_state=valor para gerar embaralhamento na saída dos dados (Fonte:

<https://medium.com/data-science-collective/what-the-heck-is-random-state-24a7a8389f3d>)

2: Valores fora do padrão do restante dos dados.

Arquitetura: O modelo está encapsulado em um objeto .pkl contendo o pipeline de pré-processamento completo. Quando um evento de abastecimento atinge o backend NestJS, o backend inicia dinamicamente um subprocesso Python para carregar o modelo, injetar o payload JSON das especificações do veículo e retornar o `co2_fossil_predicted_g_km` para calcular os pontos.

4.2. Estratégia de Validação

Estratégia de Hold-out e Prevenção de Vazamento de Dados: A validação foi realizada utilizando o conjunto de hold-out de 20% (`X_test`, `y_test`). Fundamentalmente, o pré-processamento de dados (`OneHotEncoder`) foi encapsulado dentro do `sklearn.pipeline.Pipeline`. Isso garante que as transformações de dados sejam ajustadas ao conjunto de treinamento durante o `pipeline.fit()`, prevenindo qualquer vazamento estatístico do conjunto de teste para os parâmetros do modelo antes da avaliação.

```
[13]: from sklearn.model_selection import train_test_split
      from sklearn.preprocessing import OneHotEncoder
      from sklearn.compose import ColumnTransformer
      from sklearn.pipeline import Pipeline
      from sklearn.ensemble import RandomForestRegressor

      cat_features = ['Transmission', 'Fuel_Type', 'Vehicle_type']
      num_features = ['Engine_Size_L', 'Cylinders', 'Fuel_Consumption_Comb_L_per_100_km']

      preprocessor = ColumnTransformer(
          transformers = [
              ('num', 'passthrough', num_features),
              ('cat', OneHotEncoder(handle_unknown='ignore'), cat_features)
          ])
      X_train, X_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)
```

```
[14]: X_train
```

```
[14]:
```

	Engine_Size_L	Cylinders	Transmission	Fuel_Type	Fuel_Consumption_Comb_L_per_100_km	Vehicle_type
6590	3.0	6	AS8	Z	9.9	SUBCOMPACT
6274	4.0	6	A5	X	12.7	PICKUP TRUCK - SMALL
2251	3.0	6	M6	Z	11.7	COMPACT
3149	3.4	6	AM7	Z	9.8	TWO-SEATER
4362	2.0	4	AS8	Z	8.7	STATION WAGON - MID-SIZE
...	...	...	...	...	...	...
5191	2.0	4	M6	Z	9.0	SUBCOMPACT
5226	3.5	6	AV7	X	9.1	MID-SIZE
5390	3.5	6	AS8	X	10.4	SUV - STANDARD
860	2.5	4	AV	X	8.6	SUV - SMALL
7270	4.0	8	AM8	Z	11.9	FULL-SIZE

5908 rows × 6 columns

4.3. Desempenho e Métricas

Métrica de Avaliação	Resultado Alcançado	Interpretação de Negócio
R² Score	0.996429065879812	Representa a porcentagem da variação nas emissões de CO ₂ do veículo. Um R ² elevado comprova que as características técnicas escolhidas são determinantes das emissões reais, garantindo o estabelecimento de uma linha de base justa para cada condutor.
MAE(Mean Absolute Error)³	1.9034969967008641	Traduz a margem de erro em termos operacionais tangíveis. Um MAE extremamente baixo significa que o valor de co2_fossil_predicted_g_km gerado por evento de abastecimento é sólido, garantindo que os BioPoints sejam distribuídos equitativamente, sem prejuízo financeiro para a plataforma.

$$MAE = \frac{1}{n} \sum \left| y - \hat{y} \right|$$

Diagram illustrating the Mean Absolute Error (MAE) formula with annotations:

- $\frac{1}{n}$: Divide by the total number of data points
- $\sum$: Sum of
- y : Actual output value
- $\hat{y}$: Predicted output value
- $|y - \hat{y}|$: The absolute value of the residual

3:

Obs: No teste também faço um exemplo utilizando um dataset sem a variável 'Fuel_Consumption_Comb_L_per_100_km', obrigando assim ao modelo utilizar outras características do veículo para gerar o valor de emissão de gases CO2, fugindo assim de qualquer Leakage de dados possível. Esse teste resulta em um R² Score igual a 0.9303714085442931 e MAE igual à 11.061718682781224 g/km.

```
R2 Score: 0.9303714085442931
MAE: 11.061718682781224 g/km
```

```
['../ml/models/co2_model_without_fuel_consumption.pkl']
```


5. Interpretabilidade do Modelo (XAI)

Principais Fatores de Decisão:

- **Fuel_Consumption_Comb_L_per_100_km:** Demonstra a correlação direta e positiva mais forte com as emissões de CO₂.

```
[4]: import seaborn as sns
import matplotlib.pyplot as plt

direct_correlation = df['CO2_Emissions_g_per_km'].corr(df['Fuel_Consumption_Comb_L_per_100_km'])
print(f'Direct Correlation: {direct_correlation:.4f}')

Direct Correlation: 0.9181
```

Essa validação técnica comprova matematicamente a regra de negócio principal do projeto: o consumo de combustível se traduz diretamente em emissões, por isso o `efficiency_multiplier` é tão crucial para a lógica de recompensas.

- **Engine_Size_L e Cilindros:** Atuam como a linha de base fundamental secundária para a árvore de predição. Câmaras de combustão maiores elevam o limite mínimo possível de emissões, independentemente da eficiência de condução.
- **Fuel_Type & Vehicle_type:** Essas características categóricas atuam como importantes condições de ramificação na Floresta Aleatória, ajustando as métricas de penalidade/linha de base com base nas propriedades inerentes da combustão e na classe de peso do veículo (por exemplo, SUVs vs. Compactos).